

# Processamento digital de imagens

Agostinho Brito

Departamento de Engenharia da Computação e Automação  
Universidade Federal do Rio Grande do Norte

27 de maio de 2016

# Reconhecimento de objetos


- Padrão: arranjo de descritores. Característica  $\leftrightarrow$  descritor.
- Classe de padrões: família de padrões que compartilham características comuns.
- Classes de padrões são indicadas como  $\omega_1, \omega_2, \omega_3, \dots, \omega_W$ , onde  $W$  é o número de classes.
- Formas mais comuns de representação de padrões: vetores, strings e árvores.
- Formas mais comuns de classificação de padrões: estatísticas e por aprendizado de máquina.

# Reconhecimento de objetos

- Vetores

$$\mathbf{x} = [x_1, x_2, \dots, x_n]^T$$

- Ex: discriminação de flores pelas dimensões de suas pétalas:  $\mathbf{x} = [x_1, x_2]^T$ .



- Classificador de distância mínima. Verificar a distância de um padrão para cada classe com base numa função de decisão.
- Se  $d_i(\mathbf{x}) > d_j(\mathbf{x})$  *quad*  $j = 1, 2, \dots, W; i \neq j$ , diz-se que o padrão  $\mathbf{x}$  pertence à classe  $i$ .
- A média dos valores dos padrões da classe é dada por

$$\mathbf{m}_j = \frac{1}{N_j} \sum_{\mathbf{x} \in \omega_j} \mathbf{x}_j$$

- A distância para a classe  $j$  é dada por

$$d_j(\mathbf{x}) = \|\mathbf{x} - \mathbf{m}_j\| = \mathbf{x}^T \mathbf{m}_j - \frac{1}{2} \mathbf{m}_j^T \mathbf{m}_j$$

## Classificadores estatísticos ótimos

- A probabilidade de um padrão  $\mathbf{x}$  vir da classe  $\omega_i$  é denotada por  $p(\omega_i/\mathbf{x})$ .
- Se o classificador decide padrão  $\mathbf{x}$  pertence à classe  $\omega_j$  quando, na verdade, ela pertence à classe  $\omega_i$ , ocorre um erro, denotado por  $L_{ij}$
- O risco condicional médio de atribuir um padrão à classe  $\omega_j$  (para  $W$  classes) é dado por

$$r_j(\mathbf{x}) = \sum_{k=1}^W L_{kj} p(\omega_k/\mathbf{x})$$

- Como  $p(A/B) = p(A)p(B/A)/p(B)$ ,

$$r_j(\mathbf{x}) = \frac{1}{p(\mathbf{x})} \sum_{k=1}^W L_{kj} p(\mathbf{x}/\omega_k)$$

- $p(\mathbf{x}/\omega_k)$  é a função densidade de probabilidade da classe  $\omega_k$ .
  - $P(\omega_k)$  é a probabilidade de ocorrência de um indivíduo da classe  $\omega_k$ .
- Como  $1/p(\mathbf{x})$  é comum a todos os valores de  $r_j(\mathbf{x})$ , pode ser retirado da equação sem afetar a ordem de valores.

$$r_j(\mathbf{x}) = \sum_{k=1}^W L_{kj} p(\mathbf{x}/\omega_k)$$

- O classificador que minimiza a perda total média é chamado *classificador de Bayes*.
- Ao fator de perda pode ser dado, por exemplo, o valor ZERO, para uma decisão correta, e UM para uma decisão incorreta.
- A função de risco torna-se, portanto

$$r_j(\mathbf{x}) = p(\mathbf{x}) - p(\mathbf{x}/\omega_j)P(\omega_j)$$

- O classificador de Bayes atribui o padrão  $\mathbf{x}$  à classe  $\omega_i$  se, para todo  $j \neq i$ ,

$$\begin{aligned}p(\mathbf{x}) - p(\mathbf{x}/\omega_i)P(\omega_i) &< p(\mathbf{x}) - p(\mathbf{x}/\omega_j)P(\omega_j) \\ p(\mathbf{x}/\omega_i)P(\omega_i) &> p(\mathbf{x}/\omega_j)P(\omega_j)\end{aligned}$$

- Logo, as funções de decisão podem ser definidas como

$$d_j(\mathbf{x}) = p(\mathbf{x}/\omega_j)P(\omega_j) \quad j = 1, 2, \dots, W$$

- Se as classes possuem chances iguais de ocorrer

$$d_j(\mathbf{x}) = p(\mathbf{x}/\omega_j) \quad j = 1, 2, \dots, W$$

# Reconhecimento de padrões

- Classificadores bayesianos para classes com distribuição gaussiana. Ex: caso unidimensional

$$p(x/\omega_j) = \frac{1}{\sqrt{2\pi}\sigma_j} e^{-\frac{x-m_j^2}{2\sigma_j^2}} P(\omega_j)$$

- Caso n-dimensional

$$p(\mathbf{x}/\omega_j) = \frac{1}{(2\pi)^{n/2} |\mathbf{C}_j|^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\mathbf{m}_j)^T \mathbf{C}_j^{-1} (\mathbf{x}-\mathbf{m}_j)}$$

- onde

$$\mathbf{m}_j = \frac{1}{N_j} \sum_{\mathbf{x} \in \omega_j} \mathbf{x} \quad \mathbf{C}_x = \frac{1}{N_j} \sum_{\mathbf{x} \in \omega_j} (\mathbf{x}\mathbf{x}^T) - \mathbf{m}_j \mathbf{m}_j^T$$


- A forma exponencial pode ser reduzida por logaritmo

$$d_j(\mathbf{x}) = \ln[p(\mathbf{x}/\omega_j)P(\omega_j)] = \ln p(\mathbf{x}/\omega_j) + \ln P(\omega_j)$$

- Assim, a função de decisão torna-se

$$d_j(\mathbf{x}) = \ln P(\omega_j) - \frac{1}{2} \ln |\mathbf{C}_j| - \frac{1}{2} [(\mathbf{x} - \mathbf{m}_j)^T \mathbf{C}_j^{-1} (\mathbf{x} - \mathbf{m}_j)]$$

## Exemplo de classificador



- Valores das médias

$$\mathbf{m}_1 = \frac{1}{4} \begin{bmatrix} 3 & 1 & 1 \end{bmatrix}^T$$

$$\mathbf{m}_2 = \frac{1}{4} \begin{bmatrix} 1 & 3 & 3 \end{bmatrix}^T$$

- Matrizes de covariância

$$\mathbf{C}_1 = \mathbf{C}_2 = \frac{1}{16} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}$$

- Funções de decisão

$$d_1(\mathbf{x}) = 4x_1 - 1.5$$

$$d_2(\mathbf{x}) = -4x_1 + 8x_2 + 8x_3 - 5.5$$



# Reconhecimento de padrões

- Classificação de padrões por aprendizado de máquina.
- Tipos de métodos:
  - Não-supervisionado
  - Supervisionado

## Aprendizado não-supervisionado - procedimento genérico

- 1 Seja  $H_u$  um conjunto de amostras não-rotuladas.
- 2 Rotule  $H_u$  em  $H_t$  (amostras rotuladas) usando um critério qualquer.
- 3 Projete um classificador com base nessa partição.
- 4 Aplique o classificador em  $H_u$ . Se a classificação for consistente com  $H_t$ , finalize o aprendizado.
- 5 Caso contrário, atualize  $H_t$  e repita o projeto do classificador conforme passo 3.


## Exemplo: algoritmo k-means

- 1 Escolha o número de classes para vetores  $\mathbf{x}_i$  de  $N$  características,  $i = 1, 2, \dots, N_{amostras}$ .
- 2 Escolha  $\mathbf{m}_1, \mathbf{m}_2, \dots, \mathbf{m}_k$  como aproximações iniciais para os centros das classes.
- 3 Classifique cada amostra  $\mathbf{x}_i$  usando, por exemplo, um classificador de distância mínima.
- 4 Recalcule as médias  $\mathbf{m}_j$  usando o resultado de 3.
- 5 Se as novas médias são consistentes, finalize o algoritmo. Caso contrário, repita o passo 3 com as novas médias obtidas.

## Algoritmo kNN: k vizinhos mais próximos

- 1 O padrão pertencerá à classe que tiver, dentre k vizinhos mais próximos desse padrão, a maior quantidade de representantes.

## Neurônio artificial



- Função de ativação sigmóide:

$$f(x) = \frac{1}{1 + e^{-\beta x}}$$

## Redes de perceptrons de múltiplas camadas

